



## 8. 回帰

- 問題設定
  - 教師あり学習
  - 数値入力 → 数値出力



## 8.2 線形回帰

- 目標：なるべく誤差の少ない直線を求める



- 線形回帰の定義
  - 入力  $\mathbf{x}$  から出力  $y$  を求める回帰式を 1 次式に限定
  - 学習データから係数  $w$  を求める

$$\hat{c}(\mathbf{x}) = \sum_{i=0}^d w_i x_i$$

## 8.2 線形回帰

- 最小二乗法による係数の推定
  - 推定の基準：誤差の二乗和  $E$  を最小化

$$E(\mathbf{w}) = \sum_{i=1}^N (y_i - \hat{c}(\mathbf{x}_i))^2$$

$$= (\mathbf{y} - \mathbf{X}\mathbf{w})^T (\mathbf{y} - \mathbf{X}\mathbf{w})$$

$\mathbf{X}$ : 全学習データを並べた行列

$\mathbf{w}$ : 係数のベクトル表現

- $\mathbf{w}$  で微分した値が 0 となるのは

$$\mathbf{X}^T (\mathbf{y} - \mathbf{X}\mathbf{w}) = 0$$

$$\Leftrightarrow \mathbf{w} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

$\mathbf{w}$  が解析的に  
求まる

## 8.2 線形回帰

- 最小二乗法の精度向上

例  $\phi(x) = (1, x, x^2, \dots, x^b)$


- 基底関数  $\phi(x) = (\phi_1(x), \dots, \phi_b(x))$  を考える

$$\hat{c}(x) = \sum_{j=0}^b w_j \phi_j(x)$$

- 係数が線形であれば、最小二乗法が適用可能

- 問題点

- 汎化性能の低下



## 8.2 線形回帰

- 正則化

- 正則化項の導入

- 複雑なパラメータ  $w$  (過学習) の回避

- L1 ノルム  $|w|$  : 0 となるパラメータが多くなる

Lasso

- L2 ノルム  $\|w\|^2$  : パラメータを 0 に近づける

Ridge

- リッジ回帰

- 誤差の二乗和に L2 ノルム正則化項を加える

$$E(w) = (y - Xw)^T (y - Xw) + \underline{\lambda w^T w}$$

$\lambda$  : 誤差の二乗和と正則化項とのバランス

$$w = (X^T X + \lambda I)^{-1} X^T y$$

$w$  が解析的に  
求まる

## 8.2 線形回帰

- ラッソ回帰


- 誤差の二乗和に L1 ノルム正則化項を加える

$$E(\boldsymbol{w}) = (\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w})^T (\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}) + \lambda \sum_{j=1}^d |w_j|$$


- 微分不可能な点があるため、解析的に解を求めることができない
  - 適当な初期重みから始め、リッジ回帰で上界を押さえる逐次更新アルゴリズムを用いる

## 8.2 線形回帰

- リッジ回帰とラッソ回帰



パラメータを 0 に  
近づけている



0 となるパラメータを  
多くしている

## 8.4 回帰木

- 回帰木とは
  - 識別における決定木の考え方を回帰問題に適用
  - リーフを線形回帰式にしたモデル木で性能が向上

